0_4_tidyverse

March 17, 2023

1 Einführung in tidyverse - Teil 1

tidyverse ist eine Sammlung von Paketen, die die Datenmanipulation standardisieren und erleichtern.

Wir arbeiten mit dem Datensatz ae weiter, den wir schon kennen.

Wir decken in dieser Datei die SAS-Konzepte

- DROP / KEEP
- WHERE
- MERGE

ab.

1.1 Daten laden

```
[1]: library(tidyverse)
```

Attaching packages

```
tidyverse 1.3.2
      ggplot2 3.4.0
                                   0.3.5
                           purrr
      tibble 3.1.8
                           dplyr
                                   1.0.10
              1.2.1
      tidyr
                           stringr 1.4.1
      readr
              2.1.3
                           forcats 0.5.2
      Conflicts
                  tidyverse_conflicts()
     dplyr::filter() masks stats::filter()
                      masks stats::lag()
     dplyr::lag()
[2]: ae = read.csv(file = "data/ae.csv", sep = ",", header = TRUE, quote = "\"'")
[3]: head(ae)
```

		STUDYID	DOMAIN	USUBJID	AESEQ	AESPID	AETERM
		<chr></chr>	<chr $>$	<chr $>$	<int $>$	<chr $>$	<chr $>$
A data.frame: 6×35	1	CDISCPILOT01	AE	01-701-1015	1	E07	APPLICATION SIT
	2	CDISCPILOT01	AE	01-701-1015	2	E08	APPLICATION SIT
	3	CDISCPILOT01	AE	01-701-1015	3	E06	DIARRHOEA
	4	CDISCPILOT01	AE	01-701-1023	3	E10	ATRIOVENTRICU
	5	CDISCPILOT01	AE	01-701-1023	1	E08	ERYTHEMA
	6	CDISCPILOT01	AE	01-701-1023	2	E09	ERYTHEMA
()		'					

[4]: summary(ae)

STUDYID DOMAIN USUBJID AESEQ Length:1191 Length:1191 Length:1191 Min. : 1.00 Class : character Class :character Class :character 1st Qu.: 2.00 Mode : character Mode :character Mode :character Median: 4.00 Mean : 4.53

3rd Qu.: 6.00 Max. :23.00

AESPID AETERM AELLT AELLTCD
Length:1191 Length:1191 Length:1191 Mode:logical
Class:character Class:character Class:character NA's:1191

Mode :character Mode :character Mode :character

AEDECOD AEPTCD AEHLT AEHLTCD

Length:1191 Mode:logical Length:1191 Mode:logical

Class:character NA's:1191 Class:character NA's:1191

Mode : character Mode : character

AEHLGT AEHLGTCD AEBODSYS AEBDSYCD
Length:1191 Mode:logical Length:1191 Mode:logical
Class:character NA's:1191 Class:character NA's:1191

AESOC AESOCCD AESEV AESER
Length:1191 Mode:logical Length:1191 Length:1191
Class:character NA's:1191 Class:character Class:character

Mode :character Mode :character Mode :character

AEACN AEREL AEOUT AESCAN

Mode:logical Length:1191 Length:1191 Length:1191

NA's:1191 Class:character Class:character Class:character

Mode:character Mode:character Mode:character

AESCONG AESDISAB AESDTH AESHOSP Length:1191 Length:1191 Length:1191 Length:1191 Class :character Class : character Class : character Class : character Mode :character Mode : character Mode :character Mode :character

AESLIFE AESOD AEDTC AESTDTC Length:1191 Length:1191 Length:1191 Length:1191 Class : character Class :character Class : character Class :character Mode :character Mode :character Mode :character Mode : character

AEENDTC AESTDY AEENDY Length:1191 Min. :-277.00 Min. : -2.00Class : character 1st Qu.: 15.00 1st Qu.: 27.00 Mode :character Median : 32.00 Median : 53.00 Mean : 45.83 Mean : 67.14 3rd Qu.: 63.00 3rd Qu.:101.25 Max. : 366.00 Max. :211.00 NA's :26 NA's :473

[5]: head(tibble::as_tibble(ae))

	STUDYID	DOMAIN	USUBJID	AESEQ	AESPID	AETERM
	<chr $>$	<chr $>$	<chr $>$	<int $>$	<chr $>$	<chr></chr>
-	CDISCPILOT01	AE	01-701-1015	1	E07	APPLICATION SITE ERY
A tibble: 6×35	CDISCPILOT01	AE	01-701-1015	2	E08	APPLICATION SITE PRU
A tiddle: 0×30	CDISCPILOT01	AE	01-701-1015	3	E06	DIARRHOEA
	CDISCPILOT01	AE	01-701-1023	3	E10	ATRIOVENTRICULAR BL
	CDISCPILOT01	AE	01-701-1023	1	E08	ERYTHEMA
	CDISCPILOT01	AE	01-701-1023	2	E09	ERYTHEMA

[6]: dplyr::glimpse(ae)

- Rows: 1,191
- Columns: 35
- \$ STUDYID <chr> "CDISCPILOTO1", "CDISCPILOTO1",
- "CDISCPILOTO1", "CDISCPILOTO1...
- \$ DOMAIN <chr> "AE", "AE", "AE", "AE", "AE", "AE", "AE",
 "AE", "AE", "AE", "...
- \$ USUBJID <chr> "01-701-1015", "01-701-1015", "01-701-1015", "01-701-1023", "...
- \$ AESEQ <int> 1, 2, 3, 3, 1, 2, 4, 1, 2, 1, 2, 4, 1, 2, 3, 4, 10, 3, 1, 9, ...
- \$ AESPID <chr> "E07", "E08", "E06", "E10", "E08", "E09", "E08", "E04", "E05"...
- \$ AETERM <chr> "APPLICATION SITE ERYTHEMA", "APPLICATION SITE PRURITUS", "DI...
- \$ AELLT <chr> "APPLICATION SITE REDNESS", "APPLICATION SITE ITCHING", "DIAR...
- \$ AEDECOD <chr> "APPLICATION SITE ERYTHEMA", "APPLICATION SITE PRURITUS", "DI...
- \$ AEHLT <chr> "HLT_0617", "HLT_0317", "HLT_0148", "HLT_0415", "HLT_0284", "...
- \$ AEHLGT <chr> "HLGT_0152", "HLGT_0338", "HLGT_0588", "HLGT_0086", "HLGT_019...
- \$ AEBODSYS <chr> "GENERAL DISORDERS AND ADMINISTRATION SITE CONDITIONS", "GENE...
- $\$ AESOC $\$ "GENERAL DISORDERS AND ADMINISTRATION SITE CONDITIONS", "GENE...

- \$ AEREL <chr> "PROBABLE", "PROBABLE", "REMOTE",
- "POSSIBLE", "POSSIBLE", "PR...
- \$ AEOUT <chr> "NOT RECOVERED/NOT RESOLVED", "NOT RECOVERED/NOT RESOLVED", "...

```
"N", "N", "N", "...
      $ AESOD
"N", "N", "N", "...
      <chr> "2014-01-16", "2014-01-16", "2014-01-16",
$ AEDTC
"2012-08-27", "2012...
$ AESTDTC <chr> "2014-01-03", "2014-01-03", "2014-01-09",
"2012-08-26", "2012...
$ AEENDTC <chr> NA, NA, "2014-01-11", NA, "2012-08-30", NA,
"2012-08-30", NA,...
     <int> 2, 2, 8, 22, 3, 3, 3, 3, 21, 58, 125, 27, 1,
$ AESTDY
1, 23, 52, 52, 5...
$ AEENDY <int> NA, NA, 10, NA, 26, NA, 26, NA, NA, NA, NA,
NA, 1, 1, NA, NA,...
```

1.2 DROP und KEEP: Variablenselektion

Das Paket dplyr hat den Befehl **select()**, mit dem Variablen eingeschlossen und ausgeschlossen werden können.

```
[7]: # select() wählt Variablen aus

# %>% wird als Piping-Operator bezeichnet, das Ergebnis links wird als Eingabe

→rechts an erster Stelle eingegeben.

# select() in dieser Form entspricht dem KEEP.

ae1 <- ae %>% select(DOMAIN, USUBJID, AEDECOD, AEBODSYS)

head(ae1)
```

	ı	DOMAIN	USUBJID	AEDECOD	AEI
	1	<chr></chr>	<chr $>$	<chr></chr>	<ch< td=""></ch<>
-	1	AE	01-701-1015	APPLICATION SITE ERYTHEMA	GEN
A 1 4 C C 4	2^{-1}	AE	01-701-1015	APPLICATION SITE PRURITUS	GEN
A data.frame: 6×4	3	AE	01-701-1015	DIARRHOEA	GAS
	4	AE	01-701-1023	ATRIOVENTRICULAR BLOCK SECOND DEGREE	CAI
	5	AE	01-701-1023	ERYTHEMA	SKI
	6	AE	01-701-1023	ERYTHEMA	SKI
	,				,

[8]: # Die Domain soll ebenfalls entfernt werden. Mehrere Variablen werden als \sqcup \vee Vektor übergeben \neg c (DOMAIN, AEDECOD)

select mit Minus-Zeichen entspricht dem DROP.
ae2 <- ae1 %>% select(-DOMAIN)
head(ae2)

	ľ	USUBJID	AEDECOD	AEBODSYS
		<chr></chr>	<chr></chr>	<chr $>$
-	1	01-701-1015	APPLICATION SITE ERYTHEMA	GENERAL DISC
A data.frame: 6×3	2	01-701-1015	APPLICATION SITE PRURITUS	GENERAL DIS
	3	01-701-1015	DIARRHOEA	GASTROINTES
	4	01-701-1023	ATRIOVENTRICULAR BLOCK SECOND DEGREE	CARDIAC DISC
	5	01-701-1023	ERYTHEMA	SKIN AND SUB
	6	01-701-1023	ERYTHEMA	SKIN AND SUB
	,	*		

[9]: ae %>% select(ends_with("DY")) %>% head()

		AESTDY	AEENDY
		<int $>$	<int $>$
	1	2	NA
A data frama, 6 × 2	2	2	NA
A data.frame: 6×2	3	8	10
	4	22	NA
	5	3	26
	6	3	NA

[10]: ae %>% select(starts_with("AELLT")) %>% head()

		AELLT	AELLTCD
		<chr></chr>	<lgl $>$
	1	APPLICATION SITE REDNESS	NA
A data.frame: 6×2	2	APPLICATION SITE ITCHING	NA
	3	DIARRHEA	NA
	4	AV BLOCK SECOND DEGREE	NA
	5	ERYTHEMA	NA
	6	LOCALIZED ERYTHEMA	NA

[11]: ae %>% select(matches(".ST.")) %>% head()

		AESTDTC	AESTDY
		<chr $>$	<int $>$
	1	2014-01-03	2
A data.frame: 6×2	2	2014-01-03	2
A data.frame. 0 × 2	3	2014-01-09	8
	4	2012-08-26	22
	5	2012-08-07	3
	6	2012-08-07	3

1.3 WHERE: Selektion von Beobachtungen

Bedingungen können mit UND (&) und/oder ODER (|) verknüpft und mit Klammern priorisiert werden. Weitere boolsche Operatoren sind !, xor, any, all.

Folgende Operatoren stehen zur Verfügung:

 \bullet < : Kleiner als

• > : Größer als

• == : Gleich

<= : Kleiner oder gleich>= : Größer oder gleich

• != : Ungleich

• %in%: ist enthalten in

• is.na : ist missing

• !is.na : ist nicht missing

• is.null : ist null

• !is.null : ist nicht null

```
[12]: ae1 %>% filter(AEDECOD == "ERYTHEMA") %>% head()
```

	ſ	DOMAIN	USUBJID	AEDECOD	AEBODSYS
		<chr></chr>	<chr $>$	<chr $>$	<chr></chr>
-	1	AE	01-701-1023	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS
A data.frame: 6×4	2	AE	01-701-1023	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS
A data. Hame. U ^ 4	3^{-1}	AE	01-701-1023	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS
	4	AE	01-701-1097	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS
	5	AE	01-701-1111	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS
	6	AE	01-701-1111	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS

[13]: ae1 %>% filter(AEDECOD == "ERYTHEMA" & USUBJID == "01-701-1023") %>% head()

DOMAIN	USUBJID	AEDECOD	AEBODSYS
<chr></chr>	<chr $>$	<chr $>$	<chr></chr>
AE	01-701-1023	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS
AE	01-701-1023	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS
AE	01-701-1023	ERYTHEMA	SKIN AND SUBCUTANEOUS TISSUE DIS
	<chr> AE AE</chr>	<chr> <chr> AE 01-701-1023 AE 01-701-1023</chr></chr>	<chr> <chr> <chr> AE 01-701-1023 ERYTHEMA AE 01-701-1023 ERYTHEMA</chr></chr></chr>

[14]: ae1 %>% filter(AEDECOD == "ERYTHEMA" | USUBJID == "01-701-1023") %>% head()

		DOMAIN	USUBJID	AEDECOD	AEI
		<chr></chr>	<chr $>$	<chr></chr>	<ch< td=""></ch<>
A data.frame: 6×4	1	AE	01-701-1023	ATRIOVENTRICULAR BLOCK SECOND DEGREE	CAI
	2	AE	01-701-1023	ERYTHEMA	SKI
	3	AE	01-701-1023	ERYTHEMA	SKI
	4	AE	01-701-1023	ERYTHEMA	SKI
	5	AE	01-701-1097	ERYTHEMA	SKI
	6	AE	01-701-1111	ERYTHEMA	SKI

```
[15]: # Bestimmte Beobachtungen herausschneiden
head(ae1)
ae2 <- ae1 %>% slice(2:4)
ae2
```

		DOMAIN	N USUBJID)	AEDECOD	AEI
		<chr></chr>	<chr $>$		<chr></chr>	<ch< td=""></ch<>
_	1	AE	01-701-10	15	APPLICATION SITE ERYTHEMA	GEI
A data.frame: 6×4	2	AE	01-701-10	15	APPLICATION SITE PRURITUS	GEI
A data frame: 0×4	3	AE	01-701-10	15	DIARRHOEA	GAS
	4	AE	01-701-102	23	ATRIOVENTRICULAR BLOCK SECOND DEGREE	E CAI
	5	AE	01-701-103	23	ERYTHEMA	SKI
	6	AE	01-701-102	23	ERYTHEMA	SKI
	DO	OMAIN U	USUBJID	AF	EDECOD	AEBOI
	<0	chr> <	<chr $>$	<(chr>	<chr></chr>
A data.frame: 3×4	AI	Ξ (01-701-1015	AI	PPLICATION SITE PRURITUS	GENER
	ΑI	Ξ (01-701-1015	DI	IARRHOEA	GASTR
	AI	Ξ (01-701-1023	ΑΊ	TRIOVENTRICULAR BLOCK SECOND DEGREE	CARDI

1.3.1 MERGE BY: Verknüpfen von Datensätzen

Vier grundsätzliche Typen:

- $left_join$
- right_join
- inner join
- full join

TODO: Visualisierung über Venn-Diagramme ergänzen

```
[16]: # Die erste 4 Studienteilnehmer im Datensatz suchen head(unique(ae$USUBJID), 4)
```

1. '01-701-1015' 2. '01-701-1023' 3. '01-701-1028' 4. '01-701-1034'

```
[17]: # Diesen willkürlich zu Demo-Zwecken eine Therapie zuweisen und einen weiteren_
→Patienten ergänzen, der im Datensatz

# ae nicht vorkommt.

# rep() ist eine Funktion zur Wiederholung eines Vektors.

# seq() gehört zu dieser Funktion dazu.

USUBJID = c('01-701-1015', '01-701-1023', '01-701-1028', '01-701-1034', 
→'01-702-1001')

TRTP = c(rep(c("TRT_A", "TRT_B"), 2), "TRT_C")

Applied_TRT <- data.frame(USUBJID, TRTP)

Applied_TRT
```

```
USUBJID
                                   TRTP
                        <chr>
                                   <chr>
                       01-701-1015
                                   TRT A
     A data.frame: 5 \times 2 \quad 01-701-1023
                                   TRT B
                                   TRT A
                       01-701-1028
                       01-701-1034
                                   TRT B
                                   TRT C
                       01-702-1001
[18]: # Alle Patienten, die ein Treatment haben.
      inner_join(ae, Applied_TRT, by = c("USUBJID")) %>% select(USUBJID, AETERM,__
       →TRTP) # %>% select(USUBJID) %>% unique() %>% count()
                                                                                   TRTP
                       USUBJID
                                   AETERM
                        <chr>
                                   <chr>
                                                                                   <chr>
                                   APPLICATION SITE ERYTHEMA
                                                                                   TRT_A
                       01-701-1015
                                   APPLICATION SITE PRURITUS
                                                                                   TRT_A
                       01-701-1015
                       01-701-1015
                                   DIARRHOEA
                                                                                   TRT A
                                   ATRIOVENTRICULAR BLOCK SECOND DEGREE
                                                                                   TRT B
                       01-701-1023
                                   ERYTHEMA
                                                                                   TRT B
     A data.frame: 11 \times 3 \quad 01-701-1023
                                   ERYTHEMA
                                                                                   TRT B
                       01-701-1023
                                                                                   TRT B
                                   ERYTHEMA
                       01-701-1023
                                                                                   TRT\_A
                       01-701-1028
                                   APPLICATION SITE ERYTHEMA
                                                                                   TRT A
                                   APPLICATION SITE PRURITUS
                       01-701-1028
                       01-701-1034 APPLICATION SITE PRURITUS
                                                                                   TRT B
                                                                                   TRT B
                       01-701-1034 FATIGUE
[19]: # Alle Patienten, die kein Treatment haben.
      # Strings haben einen NA Wert.
     left_join(ae, Applied_TRT, by = c("USUBJID")) %>% select(USUBJID, AETERM, TRTP)__
       →%>% filter(is.na(TRTP)) %>% select(USUBJID) %>% unique() %>% count()
     A data.frame: 1 \times 1 <int>
[20]: # Patienten mit Treatment und ohne AE.
     right_join(ae, Applied_TRT, by = c("USUBJID")) %>% select(USUBJID, AETERM,__
       →TRTP) %>% filter(is.na(AETERM))
                       USUBJID
                                   AETERM
                                             TRTP
     A data.frame: 1 \times 3 <chr>
                                   <chr>
                                              <chr>
                       01-702-1001
                                   NA
                                              TRT C
 []:
```